


INSTITUTO TECNOLÓGICO Y DE ESTUDIOS SUPERIORES DE  
MONTERREY  
CAMPUS QUERÉTARO  
DEPARTAMENTO DE COMPUTACIÓN Y MECATRÓNICA



**Tecnológico  
de Monterrey**

Predicción del valor de criptomonedas usando el modelo híbrido  
ARIMA-LSTM

por

[Alan Macías](#)

Proyecto Integrador para el Desarrollo de Soluciones Empresariales

*Ingeniería*  
*en*  
*Sistemas Computacionales*

Asesor: Dr. Benjamín Valdés  
Co-Asesor: Dr. Alfonso Gómez

Santiago de Querétaro, Querétaro, México  
07/05/2020

## Abstract

El análisis de series temporales es utilizado comunmente para hacer proyecciones de precios, incluyendo el de las criptomonedas. Implementar modelos que hagan predicciones precisas no es una tarea sencilla, especialmente para mercados tan volátiles. Se desarrolla un modelo híbrido ARIMA-LSTM que es evaluado(RECM) contra otros modelos ya utilizados para predecir el precio de criptomonedas. Se obtuvieron resultados que demuestran que el modelo híbrido se aproxima mejor que los otros modelos al valor real de los precios.

# Índice general

<b>Abstract</b>	<b>I</b>
<b>1. Introducción</b>	<b>1</b>
1.1. Contexto del problema	1
1.2. Motivación	1
1.3. Objetivo del trabajo	2
1.4. Estructura del trabajo	2
<b>2. Estado del Arte</b>	<b>3</b>
2.1. Contexto del Área	3
2.1.1. Series de tiempo	3
2.1.1.1. Definición	3
2.1.1.2. Visualización	4
2.1.1.3. Análisis y Pronóstico de series de tiempo	4
2.2. Trabajos Relevantes	5
2.2.1. ARIMA	5
2.2.1.1. Descripción del modelo	5
2.2.1.2. Pronósticos del precio de Bitcoin	5
2.2.2. LSTM	5
2.2.2.1. Descripción del modelo	5
2.2.2.2. Pronósticos del precio de Bitcoin	6
2.2.3. ARIMA-LSTM	6
2.2.3.1. Descripción del modelo	6
2.2.3.2. Pronósticos hechos con ARIMA-LSTM	7
2.3. Conclusión	8
<b>3. Objetivo de Investigación</b>	<b>9</b>
3.1. Volatilidad de las criptomonedas	9
3.2. Trabajos anteriores	9
3.3. Objetivo de Investigación	10
<b>4. Propuesta de Solución</b>	<b>11</b>
4.1. Datos	11
4.1.1. Obtencion de datos históricos	11
4.1.2. Preprocesamiento general de datos	12
4.2. Implementación de modelos	12
4.2.1. ARIMA	12

---

4.2.1.1.	Pronósticos . . . . .	13
4.2.2.	LSTM . . . . .	13
4.2.2.1.	Ventana deslizante . . . . .	13
4.2.2.2.	Pronósticos . . . . .	14
4.2.3.	ARIMA-LSTM . . . . .	14
4.2.3.1.	Pronósticos . . . . .	15

# Capítulo 1

## Introducción

En este trabajo se presenta la investigación e implementación de un modelo híbrido de series temporales utilizado para hacer proyecciones del precio de criptomonedas (Bitcoin y Litecoin). El desarrollo del proyecto implica la implementación de dos modelos (ARIMA y LSTM) que se han utilizado actualmente para hacer proyecciones de criptomonedas y se evalúan los resultados obtenidos por dichos modelos contra un tercer modelo híbrido ARIMA-LSTM que a su vez se implementa.

### 1.1. Contexto del problema

Las criptomonedas son monedas digitales que operan de forma descentralizada, permitiendo que los usuarios lleven a cabo transacciones sin que éstas dependan de un intermediario. Las criptomonedas, y en especial Bitcoin que es la más popular, atraen cada vez más la atención haciendo que muchas personas opten por invertir en ellas y que ciertos negocios comiencen a aceptarlas como forma de pago [1]. Las criptomonedas se describen como rápidas, convenientes, libres de impuesto, e incluso revolucionarias [1], sin embargo, también son conocidas por su alta volatilidad debido a distintos factores como el tener un mercado relativamente pequeño, baja liquidez, gran cantidad de especulaciones respecto a su futuro, entre otros. Esta naturaleza volátil, hace que predecir los precios de criptomonedas sea una tarea complicada [2].

### 1.2. Motivación

La alta volatilidad de las criptomonedas hace que sean una inversión bastante riesgosa, sin embargo, actualmente se llevan a cabo más de 250, 000 transacciones de criptomonedas al día [3]. El desplome del valor de Bitcoin más reciente ocurrió el 12 de Marzo, reportando pérdidas de

prácticamente el 50 % para los inversionistas en tan solo un día [4]. A partir de datos como éstos, nace la motivación para realizar este trabajo, que busca explorar la posibilidad de acercarnos a proyecciones más precisas y así reducir el riesgo al invertir en criptomonedas.

### **1.3. Objetivo del trabajo**

El objetivo de este trabajo es determinar si las proyecciones del precio de criptomonedas hechas por el modelo híbrido ARIMA-LSTM son más certeras que las de los modelos ya hechos anteriormente.

### **1.4. Estructura del trabajo**

Este trabajo está conformado por 7 capítulos que detallan la investigación hecha y posteriormente la implementación de los modelos.

En el capítulo 2 se habla del Estado del Arte. Se explican conceptos relevantes para el proyecto en general, así como otras soluciones propuestas para la problemática.

En el capítulo 3 se describe más a detalle la problemática actual y del porqué es importante seguir buscando soluciones alternas.

En el capítulo 4 se habla a profundidad de la propuesta de solución, explicando tanto los aspectos y conceptos relevantes para su desarrollo, como el funcionamiento de los modelos a implementar.

En el capítulo 5 se define la metodología de evaluación que se utiliza, así como la justificación para la elección de la misma.

En el capítulo 6 se muestran los resultados obtenidos al evaluar cada modelo. Se aprecian visualmente las proyecciones de precios hechas por cada modelo y los precios reales para compararlos.

En el capítulo 7 se presentan las conclusiones basadas en los resultados obtenidos, se retoman puntos importantes del trabajo y se plantean posibles trabajos futuros teniendo ya una base.

## Capítulo 2

# Estado del Arte

En este capítulo se describen conceptos relevantes en el área. Posteriormente se hace mención a los modelos ARIMA y LSTM, que se han implementado para hacer pronósticos del precio de las criptomonedas, así como los resultados que obtuvieron. Analizar estos trabajos permite encontrar un área de oportunidad a la cual se puede contribuir.

### 2.1. Contexto del Área

#### 2.1.1. Series de tiempo

##### 2.1.1.1. Definición

Una serie de tiempo es un conjunto secuencial de datos medidos típicamente en tiempos sucesivos. Las medidas que se toman durante cierto periodo se organizan en orden cronológico [5]. Se define matemáticamente una serie de tiempo como:

$$\{X_1, X_2, \dots, X(t)\}, t = 1, 2, 3, \dots$$

$t$  = Tiempo transcurrido

$X(t)$ : Valor del dato medido durante un tiempo en específico.

Las series de tiempo se denominan univariantes si los registros que se tienen a lo largo del tiempo son de una sola variable, pero si los registros son de más de una variable entonces se dice que es multivariante. [5, 6] Un ejemplo de serie de tiempo univariante es el medir la temperatura de alguna máquina de forma periódica cada minuto, por otro lado si se midiera tanto la temperatura como la vibración y las revoluciones, se estaría hablando de una serie de tiempo multivariante.

### 2.1.1.2. Visualización

Para visualizar los datos de una serie de tiempo, generalmente éstos se grafican trazando las observaciones con respecto al tiempo. Esto permite tener una primer aproximación y entendimiento sobre el cómo se comporta la variable a lo largo del tiempo.

La figura 2.1 muestra la visualización de una serie de tiempo, donde se aprecian los precios de Bitcoin (en dólares) desde Enero del 2015 hasta Septiembre del 2018. El eje x representa el tiempo, y el eje y el precio de la criptomoneda.



FIGURA 2.1: Visualización de precios históricos de Bitcoin [11].

### 2.1.1.3. Análisis y Pronóstico de series de tiempo

El pronóstico de series de tiempo consiste en recolectar datos históricos de alguna variable de interés para posteriormente ser analizados y desarrollar un modelo que comprenda las relaciones que existen en los datos y que posiblemente no sean notorias. El modelo después es utilizado para hacer pronósticos del comportamiento que se espera que tenga la variable recolectada [7, 8].



## 2.2. Trabajos Relevantes

### 2.2.1. ARIMA

#### 2.2.1.1. Descripción del modelo

De todos los métodos que existen actualmente para hacer pronósticos de series de tiempo, el modelo autorregresivo integrado de promedio móvil (ARIMA) es uno de los más utilizados. Este modelo tiene una característica relativamente sencilla a grandes rasgos, y que a su vez representa una deficiencia: ARIMA asume que los valores futuros y los valores históricos se relacionan linealmente, cuando la realidad es que la mayoría de los datos de series temporales presentan una relación no lineal [9].

#### 2.2.1.2. Pronósticos del precio de Bitcoin

El modelo ARIMA es una elección muy popular para realizar pronósticos de criptomoneda, especialmente a corto plazo. Como se describe en [10], se implementó este modelo utilizando los datos históricos de Bitcoin desde Mayo del 2016, hasta finales de Marzo del 2018. Los datos obtenidos contenían información sobre el precio de apertura y cierre, el alto y bajo de cada día, entre otros [10]. Para preprocesar los datos, se removieron todas las columnas a excepción del precio de cierre, y se utilizó este dato porque es el que genera más interés para los inversionistas [11].

Para implementar el modelo ARIMA, se necesitan definir 3 valores ( $p$ ,  $d$ ,  $q$ ) utilizados para la construcción del mismo, y ya que seleccionar los valores que encajan mejor en el modelo no es una tarea sencilla, el desarrollo se realizó en el lenguaje de programación R, que cuenta con una función que encuentra los valores óptimos de forma automática [10].

Las pruebas se realizaron pronosticando los precios de cierre desde el 13 de Diciembre del 2017, hasta el 27 de Marzo del 2018, y posteriormente evaluando los precios arrojados por el modelo contra los precios reales de las mismas fechas utilizando la raíz del error cuadrático medio (RECM). La evaluación resultó en un error de 593.80 [10].

### 2.2.2. LSTM

#### 2.2.2.1. Descripción del modelo

Las Long Short-Term Memory Networks (LSTM) son un tipo de redes neuronales compuestas por una capa de entrada, una o más capas escondidas, y una capa de salida. Lo que diferencia

a las LSTM de las redes neuronales convencionales, es la estructura de sus capas escondidas que les permite recordar información por largos periodos de tiempo [12, 13]. Dentro de la capa escondida de una LSTM se encuentran celdas de memoria, que a su vez cuentan con 3 tipos de compuertas: La compuerta de entrada, la de salida y la de olvido. A grandes rasgos estas compuertas mantienen y ajustan el estado de la celda, es decir, la información que ésta contiene [12].

Este modelo a diferencia del anterior, es capaz de ajustarse a relaciones no lineales en las secuencia de datos, lo que permite generar pronósticos más confiables cuando son a plazos más largos [13].

#### **2.2.2.2. Pronósticos del precio de Bitcoin**

Wu, C.-H., et al. [12] implementaron una LSTM utilizando los precios de Bitcoin desde el inicio del 2018, hasta el 28 de Julio del mismo año. El preprocesamiento de los datos fue muy similar al mencionado previamente, quedándose únicamente con el precio de cierre para el entrenamiento de los modelos y los pronósticos a generar.

Para realizar las pruebas se utilizaron los últimos 71 registros de las series de tiempo, teniendo un total de 138 muestras para entrenar al modelo. La raíz del error cuadrático medio fue una de las metodologías de evaluación usadas, resultando en un error total de 247.33 [12].

### **2.2.3. ARIMA-LSTM**

#### **2.2.3.1. Descripción del modelo**

El modelo híbrido ARIMA-LSTM combina ambos modelos aprovechando las ventajas que cada uno ofrece, buscando lograr pronósticos más precisos. Primero se utiliza el modelo ARIMA para ajustar las relaciones lineales en los datos y posteriormente el modelo LSTM se encarga de las relaciones no lineales [9].

La secuencia de pasos para hacer pronósticos de series de tiempo con el modelo ARIMA-LSTM se representa en la figura 2.2. A grandes rasgos, los pasos son los siguientes:

1. Entrenar el modelo ARIMA con los datos históricos de las series de tiempo.
2. Obtener la secuencia residual resultante.
3. Ajustar el modelo LSTM utilizando los residuos de ARIMA.
4. Pronosticar con el modelo ARIMA del paso 1.

5. Pronosticar con el modelo LSTM del paso 3.
6. Sumar ambos resultados para obtener el pronóstico final [14].

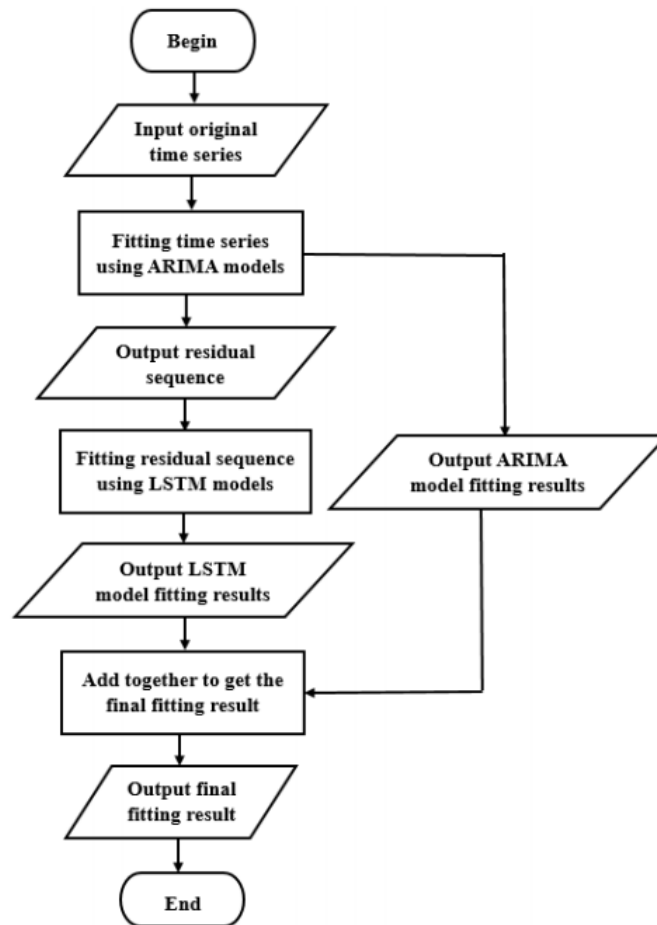


FIGURA 2.2: Diagrama de flujo del modelo ARIMA-LSTM [14].

### 2.2.3.2. Pronósticos hechos con ARIMA-LSTM

Wang, Z., & Lou, Y. propusieron un modelo de series temporales ARIMA-LSTM para pronosticar el nivel de agua promedio de una estación hidrológica ubicada en el río Chuhe. Para ponerlo a prueba, desarrollaron los modelos de forma independiente y de forma híbrida para ver si en conjunto conseguían mejores resultados. Sus experimentos mostraron que las ventajas de ambos modelos se complementan, y logran pronósticos más precisos [9].

Liu, J., Tan, X., & Wang, Y. desarrollaron el modelo ARIMA-LSTM para pronosticar el envejecimiento del software para servicios en la nube. Su propuesta (muy similar a la anterior) buscaba comprobar si se podían obtener mejores resultados usando el modelo híbrido. Para comprobarlo, obtuvieron registros diarios del Centro de Datos de Google Cloud, teniendo acceso al uso del CPU y la memoria de más de 1600 máquinas. Después de evaluar los tres modelos, la raíz del

error cuadrático medio de ARIMA-LSTM fue la menor de todas, concluyendo que se puede reducir el error y hacer mejores pronósticos con el modelo híbrido [14].

## 2.3. Conclusión

Actualmente existen varios métodos utilizados para pronosticar el precio de criptomonedas. Los trabajos previamente mencionados muestran el uso de distintos modelos de series temporales, así como las evaluaciones de los mismos. El punto más interesante a notar es el resultado que se obtiene al comparar el modelo híbrido ARIMA-LSTM contra ellos mismos de forma individual, ya que se han hecho pronósticos con un menor margen de error.

A pesar de los resultados favorables, el modelo ARIMA-LSTM no se ha utilizado comúnmente para hacer pronósticos de series de tiempo, y en particular, no se ha utilizado para pronosticar el precio de criptomonedas. A partir de esto se detecta un área de oportunidad, ya que es posible que el modelo híbrido también sea una mejor alternativa que ARIMA y que LSTM, misma que no se ha puesto a prueba aún.

## Capítulo 3

# Objetivo de Investigación

En este capítulo se habla acerca de la gran volatilidad de las criptomonedas y del cómo ha afectado a inversionistas. Posteriormente se habla acerca de un área de oportunidad que se presenta como una alternativa para posiblemente acercarse a pronósticos más precisos del precio de las criptomonedas.

### 3.1. Volatilidad de las criptomonedas

La alta volatilidad de las criptomonedas es un hecho que hace que la mayoría de las personas tengan cuidado al invertir en ellas, pero esto no siempre ha sido así. Uno de los principales momentos en los que Bitcoin fue el centro de atención ocurrió en el 2017, año en el que se registró un aumento desmesurado en los precios de dicha criptomoneda. Esto atrajo a un gran número de inversionistas con poca experiencia aprovechando la “oportunidad de su vida”, sin saber que en poco tiempo tendrían pérdidas masivas de hasta un 96 % con respecto a su inversión inicial en algunos casos [15].

Las fluctuaciones drásticas en el precio de Bitcoin siguen siendo algo común al día de hoy; el desplome del valor de Bitcoin más reciente ocurrió el 12 de Marzo, reportando pérdidas de prácticamente el 50 % para los inversionistas en tan solo un día [4]. Esto no ha impedido que las criptomonedas sigan siendo una opción popular de inversión, actualmente se llevan a cabo más de 250, 000 transacciones de criptomonedas al día [3].

### 3.2. Trabajos anteriores

Previamente se habló de ARIMA y de LSTM, dos modelos utilizados comúnmente para hacer pronósticos de criptomonedas. En cuanto a la implementación de dichos modelos no existe

algún problema en particular, desde la forma en que se desarrollaron hasta la metodología de evaluación, sin embargo, es importante hacer énfasis en el modelo híbrido ARIMA-LSTM, ya que los resultados obtenidos por este modelo fueron positivos al probarse contra ARIMA y contra LSTM como se menciona en el capítulo anterior, y esta comparación de modelos aún no se ha llevado a cabo para pronósticos del precio de criptomonedas.

A partir de esto se detecta un área de oportunidad, ya que es posible que el modelo híbrido también sea una mejor alternativa que ARIMA y que LSTM, misma que no se ha puesto a prueba aún.

### **3.3. Objetivo de Investigación**

Es importante seguir buscando alternativas que permitan acercarse a pronósticos más precisos y así reducir el riesgo al invertir en criptomonedas.

El área de oportunidad detectada, permite definir un objetivo de investigación claro: Determinar si los pronósticos del precio de criptomonedas hechos por el modelo híbrido ARIMA-LSTM son más precisos que los pronósticos de los modelos ARIMA y LSTM.

## Capítulo 4

# Propuesta de Solución

Como solución para cumplir con el objetivo de investigación planteado, primero se obtuvieron datos históricos de las criptomonedas Bitcoin y Litecoin, posteriormente se desarrollaron los tres modelos a comparar (ARIMA, LSTM, ARIMA-LSTM), entrenándolos con una parte de los datos obtenidos, y finalmente se hicieron pronósticos que después podrán ser evaluados contra los datos no utilizados aún. Todo el proceso se llevó a cabo usando el lenguaje de programación Python.

### 4.1. Datos

#### 4.1.1. Obtencion de datos históricos

Los datos históricos a utilizar tanto para entrenar como probar los modelos fueron obtenidos de CoinMarketCap, que cuenta con datos relevantes de las criptomonedas día a día. Antes el sitio web ofrecía la opción de descargar estos datos pero actualmente ya no está disponible, por lo que se tuvo que acceder a la página directamente desde Python para obtener los datos necesarios. [16, 17]

Date	Open*	High	Low	Close**	Volume	Market Cap
May 17, 2020	9374,93	9823,00	9349,55	9670,74	40.084.250.663	177.745.404.470
May 16, 2020	9333,24	9564,20	9260,69	9377,01	36.164.766.408	172.340.956.579
May 15, 2020	9734,29	9755,83	9261,40	9328,20	48.158.802.327	171.436.341.789
May 14, 2020	9271,33	9793,27	9255,03	9733,72	56.426.907.637	178.881.641.547
May 13, 2020	8805,39	9317,88	8805,39	9269,99	45.558.144.023	170.352.710.071

FIGURA 4.1: Muestra de datos históricos de Bitcoin en dólares [16].

### 4.1.2. Preprocesamiento general de datos

El preprocesamiento de datos se realizó como en el estado del arte, desechando todas las columnas a excepción de la fecha y el precio de cierre. El resultado del preprocesamiento es una serie de tiempo univariante que se define como:

$$\{X_1, X_2, \dots, X(t)\}, t = 1, 2, 3, \dots$$

$t$  = Fecha dada por Día, Mes y Año

$X(t)$ : Precio de cierre de la criptomoneda en una fecha en particular

## 4.2. Implementación de modelos

Es prácticamente imposible encontrar modelos que se hayan entrenado y evaluado utilizando las mismas fechas, y aunque se diera la casualidad de encontrarlos, éstos no estarían evaluados con los datos históricos más recientes. Por estas razones la propuesta de solución implica implementar los tres modelos utilizando los mismos datos para que los resultados obtenidos sean más acertados.

Las fechas utilizadas para entrenar los modelos fueron desde 01/01/2017 hasta 31/12/2019, dejando todos los precios de cierre del 2020 para hacer las pruebas y evaluar cada modelo. Estas fechas aplicaron para hacer los pronósticos de ambas criptomonedas, Bitcoin y Litecoin.

### 4.2.1. ARIMA

La implementación de este modelo es relativamente rápida, ya que las series de tiempo se pueden usar de forma directa para entrenar al modelo y que éste se ajuste a los datos.

Así como se mencionó en el estado del arte, no es una tarea sencilla elegir los tres valores que encajan mejor para construir el modelo ARIMA, y a diferencia de R, Python no cuenta con una función capaz de encontrarlos automáticamente. Como la cantidad de datos obtenidos no es elevada, es posible encontrar los valores que ajustan al modelo de la mejor forma probando todas las combinaciones posibles y evaluando su desempeño, logrando esto en un tiempo no muy elevado.

El modelo seleccionado fue ARIMA(4, 1, 4) y éste fue utilizado para hacer los pronósticos y posteriormente compararse contra los modelos LSTM y ARIMA-LSTM.



#### 4.2.1.1. Pronósticos

Para hacer los pronósticos con ARIMA, se tomó ventaja de la velocidad con la que se entrena el modelo. Para cada una de las fechas de prueba, se siguieron estos pasos:

1. Pronosticar el precio de cierre para la fecha correspondiente.
2. Agregar el precio real a los precios usados para el entrenamiento.
3. Reentrenar el modelo [19].

#### 4.2.2. LSTM

El primer paso para implementar este modelo fue normalizar los datos después de hacer el preprocesamiento general, para lograr esto se utilizó la librería scikit-learn, específicamente haciendo uso de su MinMaxScaler que ofrece para normalizar los datos y que éstos se encuentren en una escala de 0 a 1 [13].

A diferencia del modelo ARIMA, las LSTM no se pueden entrenar de forma directa con tan solo tener la serie de tiempo.




FIGURA 4.2: Estructura de un Perceptrón [18].

La figura 4.2 muestra la estructura más básica de una red neuronal, pero es suficiente para entender el problema que presentan los datos actualmente. Las redes neuronales reciben un cierto número de datos de entrada para al final tener uno o más datos de salida (en este caso uno, ya que los pronósticos serán únicamente del precio de cierre) [18], pero actualmente la serie de tiempo sólo tiene un valor, el precio de cierre, registrado para cada día, entonces... ¿Cómo se determina qué valores se usan como entrada y cuál es la salida esperada para entrenar al modelo?

##### 4.2.2.1. Ventana deslizante

Dada una secuencia de números representados por series de tiempo, es posible reestructurarlos para hacer que tengan el formato que espera la red neuronal (cierto número de datos de entrada

y un dato de salida). Esto se logra utilizando los valores de periodos de tiempo anteriores como datos de entrada, y el periodo siguiente como dato de salida. El número de periodos anteriores a tomar por cada fecha depende de un ancho de ventana que se define previo a la reestructuración de los datos [19]. Las siguientes tablas muestran un ejemplo de este proceso aplicado a los precios de Bitcoin.

TABLA 4.1

TABLA 4.2

Como se puede apreciar, las primeras fechas que se encuentran dentro del ancho de la ventana, tienen al menos un valor anterior desconocido, por lo que estas fechas fueron descartadas por completo. Es importante mencionar que la implementación de la ventana deslizante se efectuó una vez que los precios ya estaban normalizados, las figuras anteriores son únicamente un ejemplo para mostrar cómo se reestructura una serie de tiempo.

#### 4.2.2.2. Pronósticos

Para hacer pronósticos, lo primero que se hizo fue construir el modelo haciendo uso de la librería Keras, que permite crear redes neuronales de forma fácil y rápida [13]. En cuanto a la arquitectura de la red neuronal, se agregó una capa escondida LSTM con  $N$  nodos, que recibe de entrada los precios correspondientes a los valores anteriores. Después se agregó una capa Dense con un nodo que se utilizó para ser el valor de salida, es decir, el pronóstico del precio de cierre. Para cada una de las fechas de prueba, se utilizaron los  $N$  precios de cierre anteriores para hacer el pronóstico del siguiente día. El valor de salida de la LSTM se encontraba dentro de la escala de 0 a 1, por lo que se tuvo que desnormalizar para obtener el pronóstico final del día.

#### 4.2.3. ARIMA-LSTM

La implementación de este modelo se basó en el algoritmo presentado en el capítulo 2.

Después del preprocesamiento general se implementó el modelo ARIMA con las mismas configuraciones que ARIMA implementado individualmente, la diferencia ahora fue que después de entrenar el modelo se obtuvieron los residuales para entrenar la LSTM.

Un residual es la diferencia entre una observación y un pronóstico para una fecha, si se juntan todos los residuales se obtiene una secuencia de datos que contiene las relaciones que posiblemente el modelo ARIMA no pudo capturar por ser un modelo lineal.

Una vez se obtuvo la secuencia residual, se realizó exactamente el mismo procedimiento para entrenar la LSTM, la diferencia es que ahora la serie de tiempo a utilizar, a normalizar, y a

reestructurar usando la ventana deslizante, se construyó a partir de los residuos de ARIMA, esperando que fuera posible ajustarse a ellos con ayuda de un modelo no lineal [9].

#### 4.2.3.1. Pronósticos

Los pronósticos de ARIMA-LSTM se efectuaron haciendo pronósticos con ambos modelos de la misma forma en la que se hizo con cada uno y combinándolos. Los pasos para hacer los pronósticos para cada fecha fueron los siguientes:

1. Pronosticar el precio de cierre usando ARIMA.
2. Pronosticar el residuo usando LSTM.
3. Desnormalizar el residuo pronosticado.
4. Sumar los pronósticos de ambos modelos.
5. Calcular el residuo del día usando el precio real y el pronóstico de ARIMA.
6. Normalizar el residual.
7. Agregar el nuevo residual a los datos de entrada para la LSTM
8. Agregar el precio real a los precios usados para el entrenamiento de ARIMA.
9. Reentrenar el modelo ARIMA [14].

# Bibliografía

- [1] M. Rahouti, K. Xiong and N. Ghani, "Bitcoin Concepts, Threats, and Machine-Learning Security Solutions,in IEEE Access, vol. 6, pp. 67189-67205, 2018.
- [2] Asante, S. Are Bitcoins price predictable? Evidence from machine learning techniques using technical indicators. 2019. pp. 2.
- [3] Beck et al. Sensing Social Media Signals for Cryptocurrency News . 2019. pp. 1-2.
- [4] Bovaird, C. (2020). Bitcoin Lost Roughly 50 % Of Its Value In A Day. Mayo 4, 2020, de Forbes Sitio web: <https://www.forbes.com/sites/cbovaird/2020/03/12/bitcoin-lost-roughly-50-of-its-value-in-a-day>
- [5] Adhikari, R; Agrawal R. An Introductory Study on Time Series Modeling and Forecasting. pp. 12-13.
- [6] John H. Cochrane, "Time Series for Macroeconomics and Finance", Graduate School of Business, University of Chicago, spring 1997.
- [7] G.P. Zhang, "A neural network ensemble method with jittered training data for time series forecasting", Information Sciences 177 (2007), pp: 5329–5346.
- [8] G.P. Zhang, "Time series forecasting using a hybrid ARIMA and neural network model", Neurocomputing 50 (2003), pp: 159–175.
- [9] Wang, Z., & Lou, Y. (2019). Hydrological time series forecast model based on wavelet de-noising and ARIMA-LSTM. 2019 IEEE 3rd Information Technology, Networking, Electronic and Automation Control Conference (ITNEC).
- [10] Yenidogan, I., Cayir, A., Kozan, O., Dag, T., & Arslan, C. (2018). Bitcoin Forecasting Using ARIMA and PROPHET. 2018 3rd International Conference on Computer Science and Engineering (UBMK).
- [11] Anupriya, & Garg, S. (2018). Autoregressive Integrated Moving Average Model based Prediction of Bitcoin Close Price. 2018 International Conference on Smart Systems and Inventive Technology (ICSSIT).

- [12] Wu, C.-H., Lu, C.-C., Ma, Y.-F., & Lu, R.-S. (2018). A New Forecasting Framework for Bitcoin Price with LSTM. 2018 IEEE International Conference on Data Mining Workshops (ICDMW).
- [13] S. Tandon, S. Tripathi, P. Saraswat and C. Dabas, "Bitcoin Price Forecasting using LSTM and 10-Fold Cross validation," 2019 International Conference on Signal Processing and Communication (ICSC), NOIDA, India, 2019, pp. 323-328.
- [14] Liu, J., Tan, X., & Wang, Y. (2019). CSSAP: Software Aging Prediction for Cloud Services Based on ARIMA-LSTM Hybrid Model. 2019 IEEE International Conference on Web Services (ICWS).
- [15] Kaplan, M. (2018). Bitcoin crash: This man lost his savings when cryptocurrencies plunged. Mayo 16, 2020, de CNN Sitio web: <https://money.cnn.com/2018/09/11/investing/bitcoin-crash-victim/index.html>
- [16] <https://coinmarketcap.com/currencies/bitcoin/historical-data/>
- [17] <https://coinmarketcap.com/currencies/litecoin/historical-data/>
- [18] Nielsen, M. A. (2018). Neural Networks and Deep Learning [misc]. Determination Press
- [19] Brownlee, J. (2017). Introduction to Time Series Forecasting with Python: How to Prepare Data and Develop Models to Predict the Future. Machine Learning Mastery.